第一题

一. 思路

第一步：先导入 **tsv** 文档

第二步：用分组 **groupby** 方法，排序的方法求出死亡人数

第三步：根据条件找到 **Ms** 里大于 **3** 的震级。再把时间排序，画出时间序列图。观察趋势。

第四步：定义函数，先用列表长度 **len** 求地震总数，再对震级进行排序，最后写两个函数获取日期和地点。

二. 代码

1.1

```
*[8]: # 第一题代码
# import pandas
import pandas as pd
# import numpy
import numpy as np
# import matplotlib
from matplotlib import pyplot as plt
# make plots appear and be stored within the notebook
%matplotlib inline
```

```
[9]: # 引入tsv文档
Sig_Eqs = pd.read_csv("earthquakes-2026-10-27_15-13-38_+0800.tsv",sep="\t")
# 读前5行 看看文件有什么内容
Sig_Eqs.head()
```

```
: # 1.1
# 计算自公元前2150年以来每个国家的死亡人数
# 先把国家分组
DP = Sig_Eqs.groupby("Country") ["Deaths"].sum()
# 打印死亡最多的20个国家及死亡人数
maxDP = DP.sort_values(ascending=False).head(20)
maxDP
```

##1.2

```
# 1.2 计算MS
# 筛选等级大于3的地震
EQ = Sig_Eqs[Sig_Eqs["Ms"] > 3.0]
# 把年份分组
year1 = EQ.groupby("Year").size()
year1 = year1.sort_index()
# 绘制时间序列图
year1.plot()
plt.show()
# 趋势
# 随时间的增长，震级的次数越来越多
# 原因可能是：时代在进步，技术发展了，越来越多的地震现象被观察或观测。
```

##1.3

```
# 1.3 定义函数
def CountEq_LargestEq(country):
    # 统计各个国家的地震次数
    data = Sig_Eqs[Sig_Eqs["Country"] == country]

    count = len(data)

    data = data.dropna(subset=["Mag"])

    if len(data) == 0:
        return count, "Unknown", "Unknown"
    # 按照震级大小排序
    largest = data.sort_values("Mag", ascending=False).iloc[0]

    year = str(int(largest["Year"]))

    date = year

    if pd.notna(largest["Mo"]):
        date += "-" + str(int(largest["Mo"])).zfill(2)

        if pd.notna(largest["Dy"]):
            date += "-" + str(int(largest["Dy"])).zfill(2)
    # 提取发生地点
    location = largest["Location Name"]
    # 返回值
    return count, date, location
```

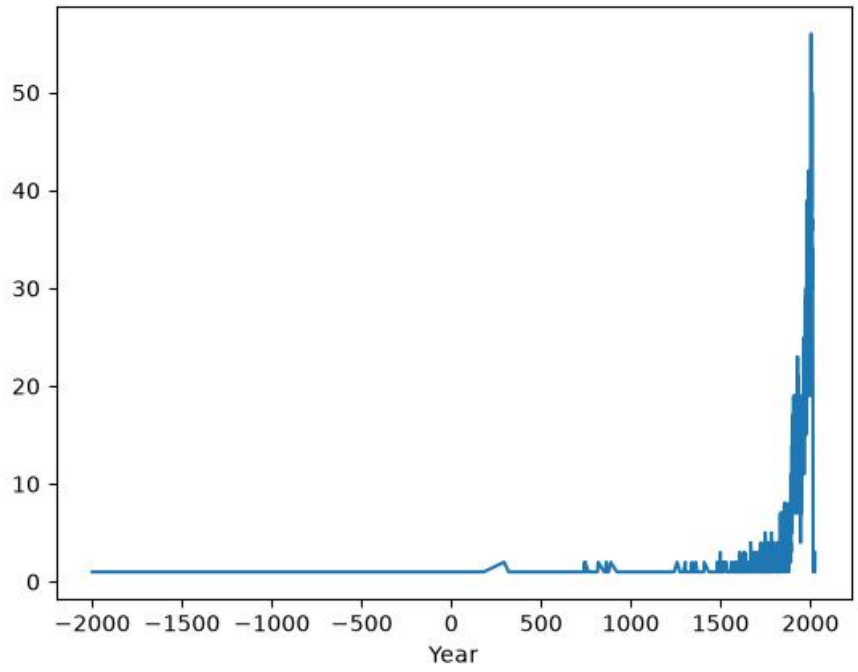
三．运行结果

#1.1

```
Country
CHINA          2139225.0
TURKEY         1199720.0
IRAN           1014438.0
ITALY           492236.0
HAITI           323484.0
AZERBAIJAN      319251.0
SYRIA           289826.0
JAPAN           242516.0
ARMENIA         177890.0
PAKISTAN        145085.0
IRAQ            136200.0
ECUADOR         135496.0
TURKMENISTAN    117412.0
PERU            102309.0
ISRAEL           93388.0
PORTUGAL         83572.0
GREECE           81162.0
CHILE            64277.0
INDIA            63507.0
TAIWAN           57154.0
Name: Deaths, dtype: float64
```

##1.2

```
# 随时间的增长，震级的次数越来越多
# 原因可能是：时代在进步，技术发展了，越来越多的地震现象被观察或观测。
```



##1.3

```
    # 提取发生地点
    location = largest["Location Name"]
    # 返回值
    return count, date, location
```

```
CountEq_LargestEq("CHINA")
```

```
(627, '1668-07-25', 'CHINA:  SHANDONG PROVINCE')
```

```
CountEq_LargestEq("JAPAN")
```

```
(429, '2011-03-11', 'JAPAN:  HONSHU')
```

四.说明

1.1 以及 1.2 是自己写的，在 section6，panda 里面都讲过这些知识点。1.3 中定义函数，求地震次数，提取地点是自己写的。其余部分是 chatgpt 教我的，提示有错的地方，我也修改了。

第二题

一、思路

第一步：处理 excel 表格里面的数据。

根据 NOAA 第 10—11 页的说明：

+9999：气温缺失值，需要排除。

1：通过全部质量控制检查，可以保留。

5：来自 NCEI 数据源并通过全部质量控制检查，可以保留

2、3、6、7：可疑或错误数据，应排除。

原始记录：

+0186,1

其中 0186 代表 18.6 摄氏度，1 代表通过质量检测的值

需要把 excel 里面的气温都转换为摄氏度。都除以 10.

然后把+9999,9 以及最后一位是 2、3、6、7 的数据都删除。

第二步：写代码的时候，先把不要的数据删除，用！=+999；用 isin 函数保留质量代码为 1 或 5 的值。

第三步：先把温度数据转换为实际温度，再求月平均温度，用的函数在 section6 当中有相似的过程。

第四步：画时间序列图。x 轴用 index 函数，y 轴用 values 函数。

二．代码

```python
# 第二题代码
#
import pandas as pd
import matplotlib.pyplot as plt

bw = pd.read_csv("Baoan_Weather_1998_2022.csv")

# 把TMP分为温度数值和质量检查代码
bw["Temp"] = bw["TMP"].str.split(",").str[0]
bw["Code"] = bw["TMP"].str.split(",").str[1]

# 把温度字符串转换为数字
bw["Temp"] = pd.to_numeric(bw["Temp"], errors="coerce")
bw = bw[bw["Temp"] != 9999]
bw = bw[bw["Code"].isin(["1", "5"])]

# 实际温度等于原始温度除以10
bw["Temperature"] = bw["Temp"] / 10
bw["DATE"] = pd.to_datetime(bw["DATE"])

# 求不同月份温度平均值
bw["Month"] = bw["DATE"].dt.to_period("M")
monthly = bw.groupby("Month")["Temperature"].mean()

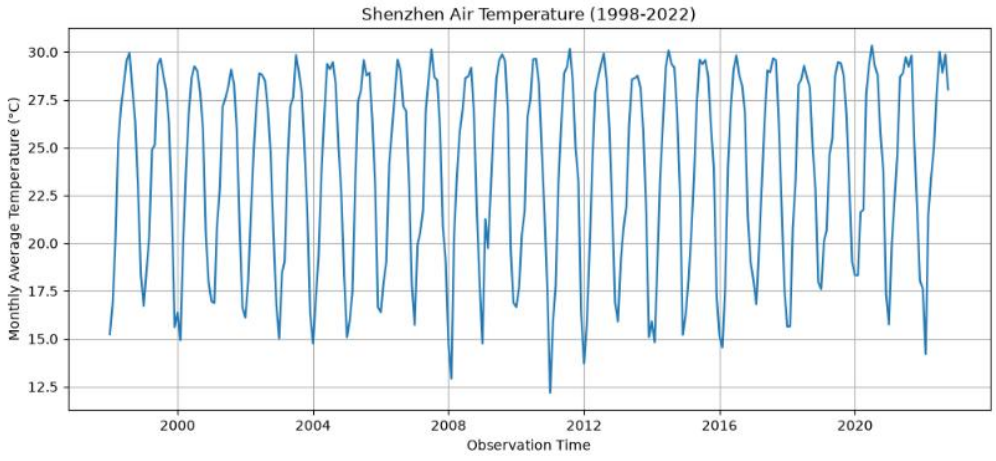
bw.head()

x = monthly.index.to_timestamp()
y = monthly.values


plt.figure(figsize=(12, 5))
plt.plot(x, y)

# 设置坐标轴名称
plt.xlabel("Observation Time")
plt.ylabel("Monthly Average Temperature (°C)")
plt.title("Shenzhen Air Temperature (1998-2022)")
plt.grid(True)
plt.show()
```

三．运行结果



四．说明

把 TMP 这列数据分为两个部分的 code 是询问 chatgpt 的。例如：+186,1 分为+186 和 1 这两个部分。

坐标轴标题的代码是求助 chatgpt 的。其余代码是自己完成的，运行之后只有显示出错，根据 gpt 的提示，我做了修改。

第三题

一．思路

第一步：3.1 利用 groupby 进行分组，运用字典对变量命名求出 3.1

第二步：20 个最大风速，用 sort_values 函数

第三步：用 groupby，size 函数找出海域数据

第四步：用 hexbin 求六边形密度图，参考老师给的指导

第五步：先筛选出山竹台风数据，然后画图，用==，&

第六步：筛选出 1970 年以后数据，用>=条件。

第七步：把每天的时间数据分组，用 resample、size、dropna 函数。最后画图

第八步：用 index.dayofyear,mean 函数，求平均值

第九步：用 loc.values 获取气候态值

二．代码

```
# 第三题代码
# import pandas
import pandas as pd
# import numpy
import numpy as np
# import matplotlib
from matplotlib import pyplot as plt

df = pd.read_csv('ibtracs.ALL.list.v04r00.csv',
    usecols=range(17),
    skiprows=[1, 2],
    parse_dates=['ISO_TIME'],
    na_values=['NOT_NAMED', 'NAME']
)

# 将风速转换为数字
df["WMO_WIND"] = pd.to_numeric(
    df["WMO_WIND"],
    errors="coerce"
)

# 确保经纬度是数字
df["LAT"] = pd.to_numeric(df["LAT"], errors="coerce")
df["LON"] = pd.to_numeric(df["LON"], errors="coerce")

# 确保时间为日期时间类型
df["ISO_TIME"] = pd.to_datetime(df["ISO_TIME"], errors="coerce")

# 查看前5行
df.head()

# 3.1题
SW = df.groupby("SID").agg({
    "NAME": "first",
    "WMO_WIND": "max"
})
NAME = SW.sort_values("WMO_WIND",ascending=False).head(10)

# 3.2
MAX_WIND = SW.sort_values("WMO_WIND",ascending=False).head(20)
```

```python
# 3.3
# 海域分组
basin = df.groupby("BASIN").size()
basin = basin.sort_values(ascending=False)

# 3.4
# 先删除没有经纬度的记录
location = df.dropna(subset=["LAT", "LON"])

plt.figure(figsize=(12, 6))

# 绘制六边形密度图
plt.hexbin(
    location["LON"],
    location["LAT"],
    gridsize=60,
    mincnt=1
)

# 设置坐标轴
plt.xlabel("Longitude")
plt.ylabel("Latitude")
plt.title("Global Tropical Cyclone Locations")

plt.show()
```

```python
# 3.5
# 筛选2018年的山竹台风
mangkhut = df[
    (df["NAME"] == "MANGKHUT") &
    (df["SEASON"] == 2018)
]

# 只保留主要轨迹
mangkhut = mangkhut[
    mangkhut["TRACK_TYPE"].str.lower() == "main"
]

# 按时间排序
mangkhut = mangkhut.sort_values("ISO_TIME")

# 设置X轴和Y轴
x = mangkhut["LON"]
y = mangkhut["LAT"]

# 绘制轨迹
plt.figure(figsize=(10, 6))
plt.plot(x, y, marker=".")

plt.xlabel("Longitude")
plt.ylabel("Latitude")
plt.title("Typhoon Mangkhut Track (2018)")
plt.grid(True)
plt.show()
```

```python
# 3.6
# 1970年以后的气旋季节
df2 = df[df["SEASON"] >= 1970]

# WP和EP两个海域
df2 = df2[df2["BASIN"].isin(["WP", "EP"])].copy()
df2.head()

# 3.7
# 筛选没有观测时间的记录
df2 = df2.dropna(subset=["ISO_TIME"])

# 每天分组
daily = df2.set_index("ISO_TIME").resample("D").size()

# 绘图
plt.figure(figsize=(12, 5))
plt.plot(daily.index, daily.values)

plt.xlabel("Date")
plt.ylabel("Number of Datapoints")
plt.title("Daily Tropical Cyclone Datapoints")

plt.show()
```

```python
# 3.8
# 提取每个日期是一年中的第几天
day_number = daily.index.dayofyear
# 按一年中的日期序号分组，计算多年平均
climatology = daily.groupby(day_number).mean()

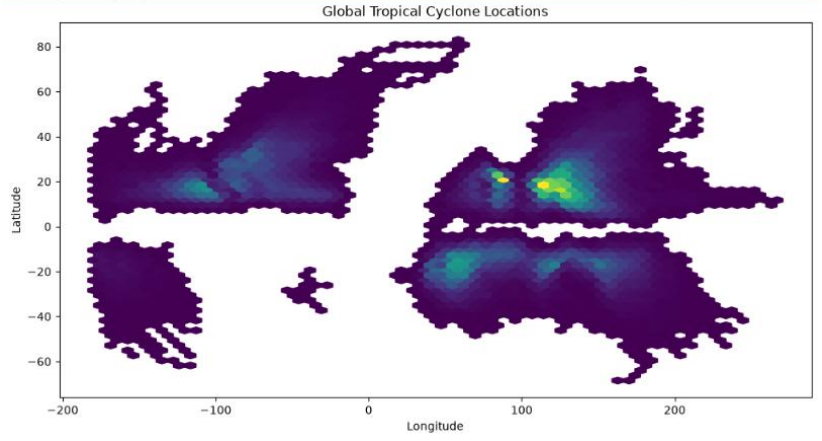
# 3.9 计算每日距平

# 获取每一天在一年中的序号
normal = climatology.loc[day_number].values
# 计算每日距平
anomaly = daily - normal

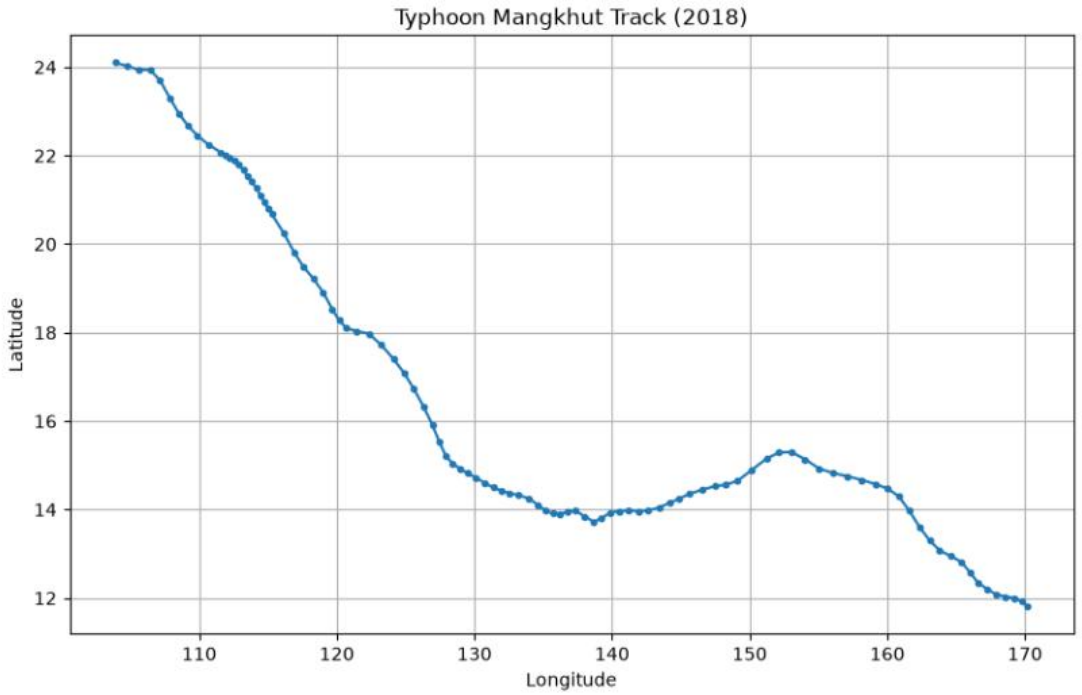
# 3.10 计算年度累计距平
# 按年份汇总每日距平
annual = anomaly.resample("YE").sum()
```

三．运行结果

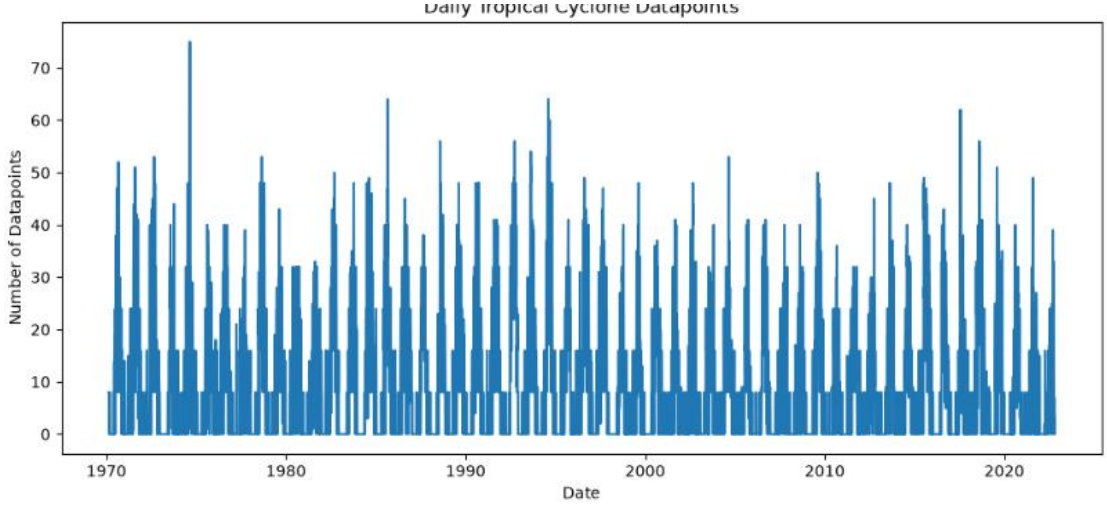
#3.4



#3.5



#3.7



四．说明

在写 3.1 之前的数据处理是 chatgpt 教我处理的，我自己写的代码运行失败，因为没有把数据转换为数字。3.8-3.10 代码都是 gpt 提供的，看不懂题目啊。3.1 的 agg 函数是 gpt 教我的，其余代码在上课的时候都学过。

第四题

一．思路

第一步：引入 csv 文档，清除空白数据，删掉缺失的数据，选择我要研究的区域

第二步：确定 x，y 轴，画时间序列图

第三步:做 5 个变量计算，根据计算公式写代码。

二．代码

```
# 第四题
# import pandas
import pandas as pd
# import numpy
import numpy as np
# import matplotlib
from matplotlib import pyplot as plt

# 4.1
df = pd.read_csv("CapeCodPFAS_2019_2024_ver_2_0.csv")

# 去掉空白数据
df["Sample_Type"] = df["Sample_Type"].str.strip()

# 筛选地下水和指定监测点
data = df[
    (df["Sample_Type"] == "GW") &
    (df["SiteID_DON"] == "413735070320730")
].copy()

# 将日期转换为日期时间类型
data["Date"] = pd.to_datetime(
    data["Date_yyyymmdd"],
    errors="coerce"
)

# 将PFOS浓度转换为数字
data["PFOS"] = pd.to_numeric(
    data["PFOS_val"],
    errors="coerce"
)

# 删除日期或浓度缺失的记录
data = data.dropna(subset=["Date", "PFOS"])
(data[["Date", "PFOS"]])
```

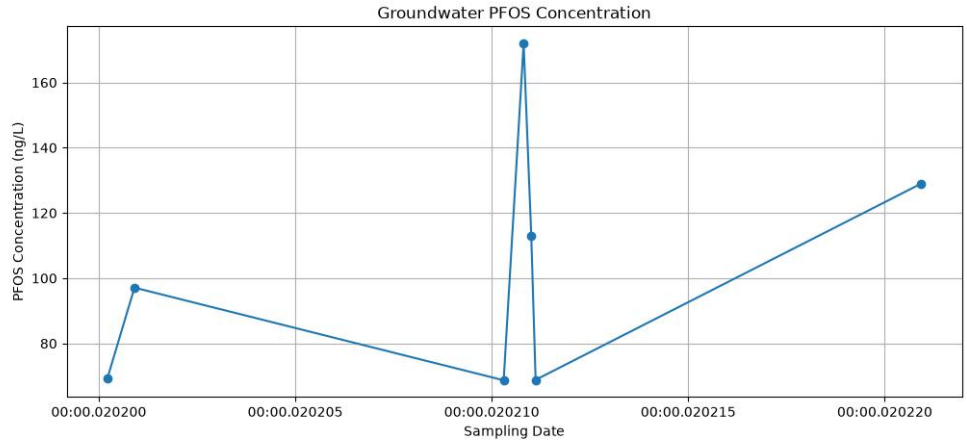
```python
# 4.2
# 指定横纵坐标
x = data["Date"]
y = data["PFOS"]

plt.figure(figsize=(12, 5))
plt.plot(x, y, marker="o")
plt.xlabel("Sampling Date")
plt.ylabel("PFOS Concentration (ng/L)")
plt.title("Groundwater PFOS Concentration")
plt.grid(True)
plt.show()

# 4.3
# 有效样本数量
Count = data["PFOS"].count()
# 平均值
Mean = data["PFOS"].mean()
Mean
# 中位数
Median = data["PFOS"].median()
# 最大值
Maximum = data["PFOS"].max()
# 最小值
Minimum = data["PFOS"].min()

print("样本数量：", Count)
print("平均值：", Mean)
print("中位数：", Median)
print("最大值：", Maximum)
print("最小值：", Minimum)
```

三．运行结果




```
样本数量： 7
平均值： 102.56142857142856
中位数： 97.1
最大值： 172.0
最小值： 68.7
```

四．说明

选择的是美国科德角地下水中 PFOS 观察的数据，PFOS 是我们

组研究的东西。代码基本上是自己完成，运行有错的地方，根据 gpt 的提示进行了修改。Gpt 对我的代码进行了优化